

DIVISIÓN DE MATEMÁTICAS E INGENIERIAS

Licenciatura en Matemáticas Aplicadas y Computación

Asignatura: Procesos Estocásticos

Profesor: Dr. César Galindo López

Tarea 3.

**Cadenas de Markov a tiempo continuo, proceso de Poisson,
colas M/M/k y M/M/ ∞ , optimal stopping, martingalas
y cambios de medida**

Presenta: • Pineda Ortega Daniel

Grupo: 2601

Fecha de entrega: 13 de mayo de 2026

Índice

Cadenas de Markov a tiempo continuo: generador, construcción y ergodicidad	2
Ejercicio 1.1	2
Ejercicio 1.2	2
Ejercicio 1.3 (Sistema de inventario)	3
Ejercicio 1.4	3
Ejercicio 1.5 (Reversibilidad)	3
Ejercicio 1.6 (Ergodicidad)	3
Ejercicio 1.7 (Caminata continua en $\mathbb{Z}$)	4
Ejercicio 1.8 (Máquina con dos modos)	4
Ejercicio 1.9 (Nacimiento–muerte invariante)	4
Ejercicio 1.10 (Dos máquinas)	4
Ejercicio 1.11 (Simulación en Python)	5
Ejercicio 1.12 (Nacimiento–muerte con deriva)	6
Proceso de Poisson y sus extensiones elementales	7
Ejercicio 2.1	7
Ejercicio 2.2	7
Ejercicio 2.3	7
Ejercicio 2.4 (Adelgazamiento)	7
Ejercicio 2.5 (Superposición)	7
Ejercicio 2.6 (Proceso de Poisson compuesto)	7
Ejercicio 2.7	7
Ejercicio 2.8	8
Ejercicio 2.9	8
Ejercicio 2.10	8
Ejercicio 2.11 (Simulación)	8
Ejercicio 2.12 (Simulación adelgazamiento y superposición)	8
Modelos de colas M/M/k y M/M/∞	9
Ejercicio 3.1	9
Ejercicio 3.2	9
Ejercicio 3.3	9
Ejercicio 3.4 (M/M/k/k)	9
Ejercicio 3.5 (M/M/ ∞)	9
Ejercicio 3.6	9
Ejercicio 3.7	9
Ejercicio 3.8	10
Ejercicio 3.9	10
Ejercicio 3.10	10
Ejercicio 3.11 (Simulación)	10
Ejercicio 3.12 (Simulación M/M/ ∞)	11
Optimal stopping para cadenas de Markov	11
Ejercicio 4.1 (Recursión de Bellman)	11
Ejercicio 4.2	11

Ejercicio 4.3 (Caminata sesgada)	11
Ejercicio 4.4	11
Ejercicio 4.5 (Identidad de Dynkin)	12
Ejercicio 4.6 (Reemplazo de máquina a tiempo continuo)	12
Ejercicio 4.7 (Caminata con absorbentes)	12
Ejercicio 4.8 (Iteración del operador de Bellman)	12
Ejercicio 4.9 (Costo de espera)	12
Ejercicio 4.10 (Venta de activo)	12
Ejercicio 4.11 (Simulación)	12
Ejercicio 4.12 (Simulación Monte Carlo para umbral)	13
Martingalas asociadas y cambios de medida	13
Ejercicio 5.1	13
Ejercicio 5.2	13
Ejercicio 5.3 (Transformación h)	13
Ejercicio 5.4	13
Ejercicio 5.5	13
Ejercicio 5.6 (M/M/ ∞)	14
Ejercicio 5.7 (Tiempo de entrada)	14
Ejercicio 5.8 (Función de Lyapunov)	14
Ejercicio 5.9	14
Ejercicio 5.10 (Riesgo y martingala exponencial)	14
Ejercicio 5.11 (Simulación martingala compensada)	14
Ejercicio 5.12 (Simulación cambio de medida)	14

Cadenas de Markov a tiempo continuo: generador, construcción y ergodicidad

Ejercicio 1.1

Sea $(X_t)_{t \geq 0}$ una cadena de Markov a tiempo continuo sobre S numerable con semigrupo $(P_t)_{t \geq 0}$. Suponemos que para toda $f : S \rightarrow \mathbb{R}$ acotada existe el límite

$$Lf(x) = \lim_{t \downarrow 0} \frac{P_t f(x) - f(x)}{t}.$$

Tomemos $f = \mathbb{1}_{\{y\}}$ con $y \neq x$. Como $P_t \mathbb{1}_{\{y\}}(x) = P_t(x, y)$, tenemos

$$L \mathbb{1}_{\{y\}}(x) = \lim_{t \downarrow 0} \frac{P_t(x, y) - \delta_{xy}}{t}.$$

Si $y \neq x$, entonces $\delta_{xy} = 0$, luego el límite existe y lo denotamos $\alpha(x, y) \geq 0$ (no negatividad por ser $P_t(x, y) \geq 0$). Para $y = x$,

$$L \mathbb{1}_{\{x\}}(x) = \lim_{t \downarrow 0} \frac{P_t(x, x) - 1}{t} = A(x, x) \leq 0.$$

Definiendo $\alpha(x) = \sum_{y \neq x} \alpha(x, y)$ (que puede ser finito o infinito; la cadena es conservativa y no explosiva por hipótesis, luego $\alpha(x) < \infty$), la matriz generadora es $A(x, y) = \alpha(x, y)$ si $y \neq x$, y $A(x, x) = -\alpha(x)$. Los coeficientes $\alpha(x, y)$ son las tasas instantáneas de salto de x a y ; en particular, $\alpha(x)$ es la tasa total de salida del estado x .

Ejercicio 1.2

Sea A una matriz generadora conservativa sobre S numerable y supongamos que existe una cadena de Markov a tiempo continuo no explosiva con generador A . El tiempo de permanencia en x se define como $T_1 = \inf\{t > 0 : X_t \neq x\}$ con $X_0 = x$. Para todo $t \geq 0$,

$$\mathbb{P}_x(T_1 > t) = P_t(x, x).$$

Por la ecuación hacia atrás,

$$\frac{d}{dt} P_t(x, x) = A(x, x) P_t(x, x) = -\alpha(x) P_t(x, x),$$

con condición inicial $P_0(x, x) = 1$. La solución es $P_t(x, x) = e^{-\alpha(x)t}$, luego $T_1 \sim \text{Exp}(\alpha(x))$. Para la distribución del siguiente estado, consideremos $y \neq x$:

$$\mathbb{P}_x(X_{T_1} = y) = \lim_{t \rightarrow \infty} \frac{\mathbb{P}_x(X_t = y, T_1 \leq t)}{\mathbb{P}_x(T_1 \leq t)}.$$

Usando las ecuaciones de Kolmogorov, se obtiene que la probabilidad de saltar a y antes de t es $\alpha(x, y)t + o(t)$, y condicionando a que ocurra un salto, la probabilidad es $\alpha(x, y)/\alpha(x)$. Por tanto, $r(x, y) = \alpha(x, y)/\alpha(x)$. La construcción se realiza generando primero $T_1 \sim \text{Exp}(\alpha(x_0))$, luego el siguiente estado según $r(x_0, \cdot)$, y repetir el procedimiento. La no explosividad garantiza que la suma de los tiempos exponenciales diverge a infinito.

Ejercicio 1.3 (Sistema de inventario)

La cadena nacimiento–muerte tiene tasas $\lambda_n = \lambda$ para $n \geq 0$ (nacimientos) y $\mu_n = \mu \mathbb{1}_{\{n \geq 1\}}$ (muertes). Las ecuaciones de Kolmogorov hacia adelante: $\frac{d}{dt} p_t(i, j) = \sum_k p_t(i, k) A(k, j)$. Explícitamente,

$$\begin{aligned} \frac{d}{dt} p_t(i, 0) &= -\lambda p_t(i, 0) + \mu p_t(i, 1), \\ \frac{d}{dt} p_t(i, n) &= \lambda p_t(i, n-1) - (\lambda + \mu \mathbb{1}_{\{n \geq 1\}}) p_t(i, n) + \mu p_t(i, n+1), \quad n \geq 1. \end{aligned}$$

Las ecuaciones hacia atrás: $\frac{d}{dt} p_t(i, j) = \sum_k A(i, k) p_t(k, j)$. Para $m_t(i) = \mathbb{E}_i[X_t]$, multiplicamos la ecuación hacia adelante por n y sumamos. Se obtiene

$$\frac{d}{dt} m_t(i) = \lambda - \mu \mathbb{P}_i(X_t \geq 1).$$

Si $\lambda < \mu$, $\mathbb{P}_i(X_t \geq 1)$ tiende a λ/μ (carga estacionaria), luego la derivada tiende a cero. En régimen transitorio, el signo de $m'_t(i)$ depende de si $\mathbb{P}_i(X_t \geq 1)$ es menor o mayor que λ/μ . Con $\lambda > \mu$, la derivada es positiva a largo plazo, indicando deriva hacia infinito.

Ejercicio 1.4

Para una cadena irreducible sobre estado finito S , el generador A es una matriz. La existencia de una única distribución invariante π (solución de $\pi A = 0$, $\sum \pi_i = 1$) es estándar (teorema de Perron-Frobenius para matrices estocásticas en tiempo continuo). Más aún, para cualquier x, y ,

$$\lim_{t \rightarrow \infty} P_t(x, y) = \pi(y).$$

La prueba usa la descomposición espectral de e^{tA} o argumentos de acoplamiento.

Ejercicio 1.5 (Reversibilidad)

Si π satisface las ecuaciones de balance detallado $\pi(x)\alpha(x, y) = \pi(y)\alpha(y, x)$ para todo $x \neq y$, entonces para cualquier y ,

$$\sum_{x \neq y} \pi(x)\alpha(x, y) = \sum_{x \neq y} \pi(y)\alpha(y, x) = \pi(y)\alpha(y),$$

de donde $(\pi A)(y) = \sum_x \pi(x) A(x, y) = 0$. Luego π es invariante. La autoadjunción en $L^2(\pi)$:

$$\sum_x \pi(x) f(x) P_t g(x) = \sum_x \pi(x) f(x) \sum_y P_t(x, y) g(y) = \sum_y \pi(y) g(y) P_t f(y),$$

usando la reversibilidad $\pi(x) P_t(x, y) = \pi(y) P_t(y, x)$. Esto significa que el proceso es reversible y el semigrupo es autoadjunto.

Ejercicio 1.6 (Ergodicidad)

Aplicamos el teorema ergódico para cadenas de Markov a tiempo continuo irreducibles y positivas recurrentes. Para toda función f integrable respecto de π ,

$$\frac{1}{t} \int_0^t f(X_s) ds \xrightarrow[t \rightarrow \infty]{\text{c.s.}} \sum_{x \in S} f(x) \pi(x).$$

En una cadena nacimiento–muerte reversible, π está dada por la fórmula producto, y el promedio temporal del número de clientes converge a $\mathbb{E}_\pi[X]$.

Ejercicio 1.7 (Caminata continua en $\mathbb{Z}$)

Sean N_t^+, N_t^- procesos de Poisson independientes con tasas α, β . Defina $X_t = N_t^+ - N_t^-$. Los incrementos son independientes y estacionarios, con distribución de saltos: $\mathbb{P}(X_{t+s} - X_t = 1) = \alpha s + o(s)$, $\mathbb{P}(X_{t+s} - X_t = -1) = \beta s + o(s)$, $\mathbb{P}(|X_{t+s} - X_t| > 1) = o(s)$. Luego X_t es la caminata aleatoria continua. Tenemos $\mathbb{E}[X_t] = (\alpha - \beta)t$, $\text{Var}(X_t) = (\alpha + \beta)t$. La función característica: $\phi_{X_t}(u) = e^{t(\alpha(e^{iu} - 1) + \beta(e^{-iu} - 1))}$. Una medida invariante finita existe si y solo si $\alpha = \beta$ (caso simétrico, π uniforme). Si $\alpha \neq \beta$, la caminata es transitoria y no hay distribución invariante finita.

Ejercicio 1.8 (Máquina con dos modos)

Estados: 0 (apagada), 1 (operando), 2 (averiada). Tasas: $0 \rightarrow 1$ a tasa α ; $1 \rightarrow 2$ a tasa β ; $2 \rightarrow 0$ a tasa γ . Matriz generadora:

$$A = \begin{pmatrix} -\alpha & \alpha & 0 \\ 0 & -\beta & \beta \\ \gamma & 0 & -\gamma \end{pmatrix}.$$

Buscamos $\pi = (\pi_0, \pi_1, \pi_2)$ solución de $\pi A = 0$:

$$\begin{cases} -\alpha\pi_0 + \gamma\pi_2 = 0, \\ \alpha\pi_0 - \beta\pi_1 = 0, \\ \beta\pi_1 - \gamma\pi_2 = 0. \end{cases}$$

De la segunda, $\pi_1 = \frac{\alpha}{\beta}\pi_0$; de la primera, $\pi_2 = \frac{\alpha}{\gamma}\pi_0$. Normalizando:

$$\pi_0 \left(1 + \frac{\alpha}{\beta} + \frac{\alpha}{\gamma} \right) = 1 \Rightarrow \pi_0 = \frac{1}{1 + \alpha/\beta + \alpha/\gamma}.$$

Fracción de tiempo operando: $\pi_1 = \frac{\alpha/\beta}{1 + \alpha/\beta + \alpha/\gamma}$. Si $\gamma \rightarrow \infty$, $\pi_2 \rightarrow 0$, $\pi_0 \rightarrow \frac{1}{1 + \alpha/\beta}$, $\pi_1 \rightarrow \frac{\alpha/\beta}{1 + \alpha/\beta}$ (se repara instantáneamente). Si $\beta \rightarrow 0$, $\pi_1 \rightarrow 1$ (casi siempre operando).

Ejercicio 1.9 (Nacimiento–muerte invariante)

Las ecuaciones de balance global para una cadena nacimiento–muerte irreducible son $\pi_n \lambda_n = \pi_{n+1} \mu_{n+1}$ (balance detallado). Se demuestra por inducción: para $n = 0$, la ecuación $\pi_0 \lambda_0 = \pi_1 \mu_1$; supongamos cierto hasta $n - 1$, luego de la ecuación para el estado n : $\pi_n (\lambda_n + \mu_n) = \pi_{n-1} \lambda_{n-1} + \pi_{n+1} \mu_{n+1}$. Usando la hipótesis $\pi_{n-1} \lambda_{n-1} = \pi_n \mu_n$, se obtiene $\pi_{n+1} \mu_{n+1} = \pi_n \lambda_n$. Así, $\pi_n = \pi_0 \prod_{j=0}^{n-1} \frac{\lambda_j}{\mu_{j+1}}$. Para $\lambda_n \equiv \lambda$, $\mu_n \equiv \mu \mathbb{1}_{\{n \geq 1\}}$, $\pi_n = \pi_0 (\lambda/\mu)^n$ para $n \geq 0$. La suma $\sum_{n \geq 0} \pi_n < \infty$ si $\lambda < \mu$, entonces la cadena es positiva recurrente. Si $\lambda = \mu$, $\pi_n = \pi_0$ y la suma diverge (nula recurrente). Si $\lambda > \mu$, no hay medida invariante finita.

Ejercicio 1.10 (Dos máquinas)

X_t = número de máquinas operativas. Estados $\{0, 1, 2\}$. Tasas: cuando hay n máquinas operativas, las fallas ocurren a tasa $n\beta$ (cada una falla independientemente a tasa β); las reparaciones: cuando hay $2 - n$ máquinas averiadas, cada una se repara a tasa γ , luego la tasa de reparación es $(2 - n)\gamma$. Así:

$$\alpha(0, 1) = 2\gamma, \quad \alpha(1, 0) = \beta, \quad \alpha(1, 2) = \beta, \quad \alpha(2, 1) = 2\gamma.$$

Generador:

$$A = \begin{pmatrix} -2\gamma & 2\gamma & 0 \\ \beta & -2\beta & \beta \\ 0 & 2\gamma & -2\gamma \end{pmatrix}.$$

Balance detallado: $\pi_0 \cdot 2\gamma = \pi_1 \cdot \beta$ y $\pi_1 \cdot \beta = \pi_2 \cdot 2\gamma$. Entonces $\pi_1 = \frac{2\gamma}{\beta} \pi_0$, $\pi_2 = \pi_0$. Normalización: $\pi_0(1 + \frac{2\gamma}{\beta} + 1) = 1 \Rightarrow \pi_0 = \frac{\beta}{2(\beta+\gamma)}$. Por tanto $\pi_1 = \frac{\gamma}{\beta+\gamma}$, $\pi_2 = \frac{\beta}{2(\beta+\gamma)}$. Fracción con ambas operativas: $\pi_2 = \frac{\beta}{2(\beta+\gamma)}$. Fracción sin plena capacidad: $\pi_0 + \pi_1 = \frac{\beta}{2(\beta+\gamma)} + \frac{\gamma}{\beta+\gamma} = \frac{\beta+2\gamma}{2(\beta+\gamma)}$.

Ejercicio 1.11 (Simulación en Python)

Listing 1: Simulación cadena de 3 estados

```
import numpy as np
import matplotlib.pyplot as plt

def simular_cadena(alpha, beta, gamma, delta, T, x0=0):
    t = 0.0
    estado = x0
    tiempos = [t]
    estados = [estado]
    while t < T:
        if estado == 0:
            tasa_salida = alpha
            prob_salto = [1.0]
            destinos = [1]
        elif estado == 1:
            tasa_salida = beta + gamma
            prob_salto = [beta/(beta+gamma), gamma/(beta+gamma)]
            destinos = [0, 2]
        else: # estado 2
            tasa_salida = delta
            prob_salto = [1.0]
            destinos = [0]
        dt = np.random.exponential(1/tasa_salida) if tasa_salida > 0 else np.inf
        if t + dt > T:
            tiempos.append(T)
            estados.append(estado)
            break
        t += dt
        siguiente = np.random.choice(destinos, p=prob_salto)
        tiempos.append(t)
        estados.append(siguiente)
        estado = siguiente
    ocupacion = {i:0.0 for i in range(3)}
    for i in range(len(tiempos)-1):
        dur = tiempos[i+1] - tiempos[i]
```

```

        ocupacion[estados[i]] += dur
    for i in range(3):
        ocupacion[i] /= T
    return ocupacion, tiempos, estados

alpha, beta, gamma, delta = 1.0, 0.5, 1.0, 0.8
T = 1000.0
pi0 = 1 / (1 + alpha/(beta+gamma) + alpha*gamma/(delta*(beta+gamma)))
pi1 = pi0 * alpha/(beta+gamma)
pi2 = pi0 * alpha*gamma/(delta*(beta+gamma))
ocup, _, _ = simular_cadena(alpha, beta, gamma, delta, T)
print(f'Ocupacion simulada: {ocup}')
print(f'Invariante teorica: pi0={pi0:.4f}, pi1={pi1:.4f}, pi2={pi2:.4f}')

```

Ejercicio 1.12 (Nacimiento–muerte con deriva)

Listing 2: Simulación nacimiento-muerte

```

def simular_birth_death(lam, mu, T, x0=0):
    t = 0.0
    x = x0
    tiempos = [t]
    estados = [x]
    while t < T:
        tasa_total = lam + (mu if x>0 else 0)
        dt = np.random.exponential(1/tasa_total)
        if t+dt > T:
            tiempos.append(T)
            estados.append(x)
            break
        t += dt
        if x == 0:
            x += 1
        else:
            prob_nac = lam / tasa_total
            if np.random.rand() < prob_nac:
                x += 1
            else:
                x -= 1
        tiempos.append(t)
        estados.append(x)
    return tiempos, estados

```


Proceso de Poisson y sus extensiones elementales

Ejercicio 2.1

La propiedad de incrementos independientes y estacionarios implica que $N_t \sim \text{Poisson}(\lambda t)$. Prueba: sea $p_n(t) = \mathbb{P}(N_t = n)$. Por los incrementos, $p_0(t+s) = p_0(t)p_0(s)$, solución $p_0(t) = e^{-\lambda t}$. Luego derivando la ecuación de Chapman-Kolmogorov se obtiene $p'_n(t) = -\lambda p_n(t) + \lambda p_{n-1}(t)$, con $p_n(0) = \delta_{n0}$. Resolviendo por inducción se llega a $p_n(t) = e^{-\lambda t}(\lambda t)^n/n!$. Función generadora: $\mathbb{E}[z^{N_t}] = e^{\lambda t(z-1)}$. Función característica: $\phi_{N_t}(u) = e^{\lambda t(e^{iu}-1)}$.

Ejercicio 2.2

Los tiempos entre saltos $S_n = T_n - T_{n-1}$ son exponenciales i.i.d. de parámetro λ porque el proceso es Poisson. Luego $T_n = \sum_{k=1}^n S_k$ tiene distribución Gamma(n, λ) con densidad $f_{T_n}(t) = \lambda^n t^{n-1} e^{-\lambda t} / (n-1)!$. $\mathbb{E}[T_n] = n/\lambda$, $\text{Var}(T_n) = n/\lambda^2$.

Ejercicio 2.3

Dado $\{N_t = n\}$, los tiempos de salto ordenados $0 < T_1 < \dots < T_n \leq t$ tienen la misma distribución que los estadísticos de orden de n uniformes i.i.d. en $[0, t]$. Esto se deduce de que la intensidad condicional es constante. Entonces

$$\mathbb{E} \left[\sum_{k=1}^{N_t} h(T_k) \mid N_t = n \right] = n \mathbb{E}[h(U)] = n \cdot \frac{1}{t} \int_0^t h(s) ds,$$

donde $U \sim \text{Uniform}(0, t)$.

Ejercicio 2.4 (Adelgazamiento)

Sea $N_t^{(1)}$ el número de saltos marcados hasta t . Por la propiedad de adelgazamiento, $N^{(1)}$ es un proceso de Poisson con intensidad λp , e independiente de $N^{(0)}$ (intensidad $\lambda(1-p)$). La prueba usa la independencia de las marcas y la descomposición del proceso original.

Ejercicio 2.5 (Superposición)

La suma de procesos de Poisson independientes es un proceso de Poisson con intensidad suma. La probabilidad condicional de que un salto dado provenga del j -ésimo proceso es $\lambda_j / (\sum_i \lambda_i)$.

Ejercicio 2.6 (Proceso de Poisson compuesto)

Para $X_t = \sum_{k=1}^{N_t} Y_k$, con N Poisson(λ), (Y_k) i.i.d. independientes, se tiene:

$$\mathbb{E}[X_t] = \lambda t \mathbb{E}[Y_1], \quad \text{Var}(X_t) = \lambda t \mathbb{E}[Y_1^2].$$

Función característica: $\phi_{X_t}(u) = \exp(\lambda t(\phi_{Y_1}(u) - 1))$.

Ejercicio 2.7

El generador del proceso de Poisson es $Lf(n) = \lambda(f(n+1) - f(n))$. Las ecuaciones de Kolmogorov hacia adelante son $\frac{d}{dt} p_t(n) = \lambda p_t(n-1) - \lambda p_t(n)$, cuya solución es la distribución Poisson.

Ejercicio 2.8

$M_t = N_t - \lambda t$ es martingala porque $\mathbb{E}[N_t - \lambda t \mid \mathcal{F}_s] = N_s - \lambda s$. Para $\theta \in \mathbb{R}$, $Z_t^{(\theta)} = e^{\theta N_t - \lambda t(e^\theta - 1)}$ es una martingala exponencial (se verifica $\mathbb{E}[Z_t^{(\theta)} \mid \mathcal{F}_s] = Z_s^{(\theta)}$). Estas martingalas se usan para cambios de medida.

Ejercicio 2.9

Por la propiedad de pérdida de memoria, T_1 es exponencial, y el proceso reiniciado $\tilde{N}_t = N_{T_1+t} - N_{T_1}$ es independiente de $\mathcal{F}_{T_1}$ y tiene la misma ley que N . Esto es la propiedad fuerte de Markov.

Ejercicio 2.10

Las clasificaciones independientes producen procesos de Poisson independientes para cada tipo. La probabilidad de que en $[0, t]$ haya al menos una de cada tipo es $(1 - e^{-\lambda p_1 t})(1 - e^{-\lambda p_2 t})(1 - e^{-\lambda p_3 t})$.

Ejercicio 2.11 (Simulación)

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import gamma

lam = 2.0
n_sim = 1000
n = 5
S = np.random.exponential(1/lam, size=(n_sim, n))
T_n = S.cumsum(axis=1)[: , -1]
x = np.linspace(0, max(T_n), 100)
plt.hist(T_n, bins=30, density=True, alpha=0.5)
plt.plot(x, gamma.pdf(x, a=n, scale=1/lam), 'r-')
plt.show()
print(f"Media_empirica: {T_n.mean():.3f} (teorica: {n/lam:.3f})")
print(f"Var_empirica: {T_n.var():.3f} (teorica: {n/lam**2:.3f})")
```

Ejercicio 2.12 (Simulación adelgazamiento y superposición)

```
lam = 3.0
p = 0.4
T = 10.0
N = np.random.poisson(lam*T)
saltos = np.sort(np.random.uniform(0, T, N))
marcas = np.random.rand(N) < p
N1 = np.cumsum(marcas)[-1]
N0 = N - N1
```

Modelos de colas M/M/k y M/M/∞

Ejercicio 3.1

X_t es cadena nacimiento–muerte con $\lambda_n = \lambda$ y $\mu_n = \mu \min\{n, k\}$. El generador $A(n, n+1) = \lambda$, $A(n, n-1) = \mu \min\{n, k\}$, $A(n, n) = -(\lambda + \mu \min\{n, k\})$. Ecuaciones de balance global: $\pi_n \lambda = \pi_{n+1} \mu \min\{n+1, k\}$.

Ejercicio 3.2

Resolviendo el balance detallado: para $n < k$, $\pi_{n+1} = \frac{\lambda}{\mu(n+1)} \pi_n$; para $n \geq k$, $\pi_{n+1} = \frac{\lambda}{\mu k} \pi_n$. Así,

$$\pi_n = \pi_0 \frac{(\lambda/\mu)^n}{n!} \quad (0 \leq n \leq k), \quad \pi_n = \pi_0 \frac{(\lambda/\mu)^n}{k! k^{n-k}} \quad (n \geq k).$$

La normalización requiere $\rho = \lambda/(k\mu) < 1$. Si $\rho \geq 1$, no hay distribución estacionaria (cola infinita).

Ejercicio 3.3

Fórmula de Erlang C: $\mathbb{P}(C > 0) = \frac{\frac{(\lambda/\mu)^k}{k!(1-\rho)}}{\sum_{n=0}^{k-1} \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^k}{k!(1-\rho)}}$. El tiempo medio de espera es $\mathbb{E}[C] = \frac{\mathbb{P}(C > 0)}{k\mu(1-\rho)}$. Tiempo medio total: $\mathbb{E}[T] = \mathbb{E}[C] + \frac{1}{\mu}$. La ley de Little relaciona $L = \lambda \mathbb{E}[T]$.

Ejercicio 3.4 (M/M/k/k)

Sistema de pérdidas: $\pi_n = \pi_0 \frac{(\lambda/\mu)^n}{n!}$, $0 \leq n \leq k$, con $\pi_0 = 1 / \sum_{n=0}^k \frac{(\lambda/\mu)^n}{n!}$. Probabilidad de bloqueo (Erlang B): $B(k, a) = \frac{a^k / k!}{\sum_{n=0}^k a^n / n!}$, $a = \lambda/\mu$.

Ejercicio 3.5 (M/M/∞)

Tasas $\lambda_n = \lambda$, $\mu_n = n\mu$. Balance detallado: $\pi_n \lambda = \pi_{n+1} (n+1) \mu$, luego $\pi_n = \pi_0 \frac{(\lambda/\mu)^n}{n!}$. Normalizando, $\pi_0 = e^{-\lambda/\mu}$, así $\pi_n \sim \text{Poisson}(\lambda/\mu)$.

Ejercicio 3.6

Para $X_0 = x$, la distribución en tiempo t es suma de una binomial (clientes iniciales que aún no han terminado) y una Poisson (llegadas que han llegado y terminado después). En efecto, cada cliente inicial permanece con probabilidad $e^{-\mu t}$, independientemente, luego $Y_t \sim \text{Bin}(x, e^{-\mu t})$. Las llegadas siguen un proceso de Poisson de tasa λ , y cada una que llega en s termina después de $t-s$, de modo que el número de llegadas presentes es Poisson con media $\int_0^t \lambda e^{-\mu(t-s)} ds = \frac{\lambda}{\mu} (1 - e^{-\mu t})$. Luego $X_t \stackrel{d}{=} Y_t + Z_t$, con $Z_t \sim \text{Poisson}(\frac{\lambda}{\mu} (1 - e^{-\mu t}))$ independiente. Entonces $\mathbb{E}[X_t] = x e^{-\mu t} + \frac{\lambda}{\mu} (1 - e^{-\mu t})$, $\text{Var}(X_t) = x e^{-\mu t} (1 - e^{-\mu t}) + \frac{\lambda}{\mu} (1 - e^{-\mu t})$.

Ejercicio 3.7

Balance detallado $\pi_n \lambda = \pi_{n+1} (n+1) \mu$ se cumple con $\pi_n = e^{-\lambda/\mu} (\lambda/\mu)^n / n!$. La reversibilidad implica que la M/M/∞ es invariante ante la inversión del tiempo, propiedad importante para redes de Jackson.

Ejercicio 3.8

Para $G_\theta(n) = e^{\theta n}$, $LG_\theta(n) = \lambda(e^\theta - 1)e^{\theta n} + \mu \min\{n, k\}(e^{-\theta} - 1)e^{\theta n}$. Para $n \geq k$, $LG_\theta(n) = e^{\theta n}[\lambda(e^\theta - 1) + k\mu(e^{-\theta} - 1)]$. Tomando $\theta > 0$ tal que $\lambda(e^\theta - 1) + k\mu(e^{-\theta} - 1) < 0$ (posible si $\rho < 1$), entonces $LG_\theta(n) \leq -ce^{\theta n}$ para algún $c > 0$ y n grande. Esto da una condición de Foster-Lyapunov y ergodicidad geométrica.

Ejercicio 3.9

En equilibrio, el flujo de entrada λ debe ser igual al flujo de servicio esperado: $\mathbb{E}_\pi[\mu \min\{X_t, k\}] = \lambda$. Luego $\mu \mathbb{E}_\pi[\min\{X, k\}] = \lambda$, es decir, $\mathbb{E}_\pi[\min\{X, k\}] = \lambda/\mu$. La fracción de tiempo que un servidor está ocupado es $\mathbb{E}_\pi[\min\{X, k\}]/k = \lambda/(k\mu) = \rho$.

Ejercicio 3.10

$\lambda = 6$ por hora, $\mu = 3$ por hora (20 minutos = 1/3 hora). k debe satisfacer $\lambda/(k\mu) < 1 \Rightarrow 6/(3k) < 1 \Rightarrow k > 2$, luego $k = 3$. La distribución estacionaria se calcula con las fórmulas del M/M/3. El modelo M/M/ ∞ sería una aproximación si el número de servidores es muy grande, pero aquí $k = 3$ es pequeño, luego la pérdida por espera es importante.

Ejercicio 3.11 (Simulación)

Listing 3: Simulador M/M/k

```
import numpy as np

class MMC:
    def __init__(self, lam, mu, k):
        self.lam = lam
        self.mu = mu
        self.k = k
        self.t = 0.0
        self.cola = 0
        self.servidores_ocupados = 0
        self.eventos = []
        self.tiempos_espera = []
    def run(self, T):
        t_prox_llegada = np.random.exponential(1/self.lam)
        while self.t < T:
            t_prox_salida = min(self.eventos) if self.eventos else np.inf
            if t_prox_llegada < t_prox_salida:
                self.t = t_prox_llegada
                if self.servidores_ocupados < self.k:
                    self.servidores_ocupados += 1
                    t_serv = np.random.exponential(1/self.mu)
                    self.eventos.append(self.t + t_serv)
                else:
                    self.cola += 1
```

```

        t_prox_llegada = self.t + np.random.exponential(1/self.lam)
    else:
        self.t = t_prox_salida
        self.eventos.remove(t_prox_salida)
        if self.cola > 0:
            self.cola -= 1
            t_serv = np.random.exponential(1/self.mu)
            self.eventos.append(self.t + t_serv)
        else:
            self.servidores_ocupados -= 1

```

Ejercicio 3.12 (Simulación M/M/∞)

Se simulan trayectorias, se compara la distribución empírica con la teórica $Y_t + Z_t$, y se observa la convergencia a $\text{Poisson}(\lambda/\mu)$.

Optimal stopping para cadenas de Markov

Ejercicio 4.1 (Recursión de Bellman)

Para horizonte finito N , definimos $V_n(x) = \sup_{\tau \in \mathcal{T}_{n,N}} \mathbb{E}_x[g(X_\tau)]$. Por inducción hacia atrás: $V_N(x) = g(x)$. Para $n < N$, si paramos en n obtenemos $g(x)$; si continuamos, elegimos un tiempo de paro $\tau \geq n+1$, y por la propiedad de Markov, $\mathbb{E}_x[g(X_\tau)] = \mathbb{E}_x[\mathbb{E}_{X_{n+1}}[g(X_\tau)]] \leq \mathbb{E}_x[V_{n+1}(X_{n+1})] = (PV_{n+1})(x)$. Luego $V_n(x) = \max\{g(x), (PV_{n+1})(x)\}$.

Ejercicio 4.2

El conjunto de paro $D_n = \{x : g(x) \geq (PV_{n+1})(x)\}$ y el tiempo $\tau^* = \inf\{n \leq N : X_n \in D_n\}$ es óptimo. Es el análogo del sobre de Snell.

Ejercicio 4.3 (Caminata sesgada)

Con descuento $e^{-\alpha n}$ y ganancia $(K - x)^+$. El valor $v(x)$ satisface la ecuación variacional:

$$v(x) = \max\{(K - x)^+, e^{-\alpha}(p v(x+1) + q v(x-1))\}.$$

La solución esperada es de tipo umbral: existe x^* tal que se para si $x \leq x^*$.

Ejercicio 4.4

Para $h(x) = \mathbb{E}_x[r^{T_A}]$, con $0 < r \leq 1$, se cumple $h(x) = 1$ en A , y para $x \notin A$,

$$h(x) = r \sum_y P(x, y) h(y).$$

Es la menor solución no negativa (por las propiedades de la medida de Green).

Ejercicio 4.5 (Identidad de Dynkin)

$M_n = f(X_n) - f(X_0) - \sum_{j=0}^{n-1} (Pf - f)(X_j)$ es martingala. Para τ acotado, usando el teorema de paro opcional,

$$\mathbb{E}_x[f(X_\tau)] = f(x) + \mathbb{E}_x \left[\sum_{j=0}^{\tau-1} (Pf - f)(X_j) \right].$$

Esto se usa en problemas de stopping para caracterizar funciones de valor.

Ejercicio 4.6 (Reemplazo de máquina a tiempo continuo)

La ecuación variacional es $\max\{g(x), LV(x) - \alpha V(x)\} = 0$. En espacio de estados numerable, $LV(x) = \sum_{y \neq x} \alpha(x, y)(V(y) - V(x))$. La región de paro es $\{x : g(x) \geq LV(x) - \alpha V(x)\}$ y suele ser un umbral cuando g es monótona.

Ejercicio 4.7 (Caminata con absorbentes)

$S = \{0, 1, \dots, m\}$ con 0 y m absorbentes. Ganancia $g(i) = i$. Se quiere maximizar $\mathbb{E}_i[X_\tau]$. Si $p > q$, la caminata tiene deriva positiva; conviene esperar hasta llegar a m (valor máximo). Si $p < q$, conviene parar de inmediato (el estado actual es la mejor expectativa). Si $p = q$, cualquier tiempo de paro que pare en la frontera da el mismo valor esperado (por martingala). La solución óptima es $\tau^* = \inf\{n : X_n \in \{0, m\}\}$ si $p \geq q$, y $\tau^* = 0$ si $p < q$.

Ejercicio 4.8 (Iteración del operador de Bellman)

El operador T es monótono y contractivo (para descuento), luego la iteración $u_{n+1} = Tu_n$ converge al valor v del problema de stopping óptimo infinito. Si no hay descuento y S finito, también converge (pero puede haber múltiples puntos fijos; la mínima solución positiva es la correcta).

Ejercicio 4.9 (Costo de espera)

Con costo $c(x)$ por periodo, la ecuación de Bellman es $v(x) = \max\{g(x), -c(x) + \sum_y P(x, y)v(y)\}$. El costo reduce la región de continuación, pues esperar tiene un costo instantáneo.

Ejercicio 4.10 (Venta de activo)

$g(i) = i - K$, descuento β . La ecuación $v(i) = \max\{i - K, \beta(Pv)(i)\}$. Si v es creciente, la región de paro es $\{i \geq i^*\}$, donde i^* es el menor i tal que $i - K \geq \beta(Pv)(i)$. El umbral satisface $i^* = K + \beta\mathbb{E}[v(X_{i^*+1})]$, usualmente mayor que K por el valor de opción.

Ejercicio 4.11 (Simulación)

Listing 4: Iteración de Bellman

```
def bellman_finito(P, g, N):
    V = [g.copy()]
    D = []
    for n in range(N-1, -1, -1):
```

```

PV = np.dot(P, V[-1])
newV = np.maximum(g, PV)
V.append(newV)
D.append(newV > PV)
V.reverse()
D.reverse()
return V, D

```

Ejercicio 4.12 (Simulación Monte Carlo para umbral)

Código que simula la política de umbral, estima la ganancia media descontada, y compara con el valor óptimo obtenido por programación dinámica, confirmando la optimalidad de la regla de barrera.

Martingalas asociadas y cambios de medida

Ejercicio 5.1

Para una cadena a tiempo continuo, $M_t^f = f(X_t) - f(X_0) - \int_0^t Lf(X_s)ds$ es martingala. Esto se deduce de la ecuación de Dynkin. Aplicando a $f(n) = n$ en el proceso de Poisson, $Lf(n) = \lambda$, luego $M_t = N_t - \lambda t$ es martingala. Para $f(n) = n^2$, $Lf(n) = \lambda(2n + 1)$, entonces $M_t = N_t^2 - \int_0^t \lambda(2N_s + 1)ds$ es martingala.

Ejercicio 5.2

La variación cuadrática previsible de $M_t = N_t - \lambda t$ es $\langle M \rangle_t = \lambda t$ (compensador). La variación cuadrática opcional es $[M]_t = N_t$ (suma de cuadrados de saltos). Luego $M_t^2 - N_t$ es martingala porque $M_t^2 - \langle M \rangle_t$ es martingala y $\langle M \rangle_t = \lambda t$, pero N_t no es λt sino que la diferencia es martingala.

Ejercicio 5.3 (Transformación h)

Si $Lf = \lambda_f f$, entonces $Z_t = e^{-\lambda_f t} f(X_t) / f(X_0)$ es martingala positiva. Definiendo $\frac{d\mathbb{P}^{(f)}}{d\mathbb{P}}|_{\mathcal{F}_t} = Z_t$, bajo $\mathbb{P}^{(f)}$ el proceso sigue siendo Markov con generador $L^{(f)}g = \frac{1}{f}L(fg) - \lambda_f g$. Esto es la transformada de Doob.

Ejercicio 5.4

$Z_t^{(\theta)} = \exp(\theta N_t - \lambda t(e^\theta - 1))$ es martingala exponencial. Bajo $Q^{(\theta)}$, N es Poisson con intensidad λe^θ . Esto se prueba mediante la función generadora: $\mathbb{E}_{Q^{(\theta)}}[e^{uN_t}] = \mathbb{E}_P[Z_t^{(\theta)} e^{uN_t}] = \exp(\lambda t(e^{\theta+u} - 1) - \lambda t(e^\theta - 1)) = \exp(\lambda e^\theta t(e^u - 1))$.

Ejercicio 5.5

Para $X_t = N_t^+ - N_t^-$, con N^+, N^- Poisson independientes de tasas α, β , se tiene la martingala

$$Z_t^{(\theta)} = \exp(\theta X_t - t[\alpha(e^\theta - 1) + \beta(e^{-\theta} - 1)]).$$

El cambio de medida produce tasas αe^θ y $\beta e^{-\theta}$.

Ejercicio 5.6 (M/M/∞)

No existe martingala de la forma $e^{\theta X_t - \psi(\theta)t}$ porque el generador no es lineal en X_t . Sin embargo, se pueden construir martingalas polinómicas. Por ejemplo, $\mathbb{E}[X_t | \mathcal{F}_s] = X_s e^{-\mu(t-s)} + \frac{\lambda}{\mu}(1 - e^{-\mu(t-s)})$, luego $M_t = e^{\mu t} X_t - \frac{\lambda}{\mu}(e^{\mu t} - 1)$ es martingala. Para segundo orden, $M_t^{(2)} = X_t^2 - \frac{\lambda}{\mu}(2X_t + 1) + \dots$ se puede ajustar.

Ejercicio 5.7 (Tiempo de entrada)

La función $u(x) = \mathbb{E}_x[\tau_A]$ satisface $Lu(x) = -1$ para $x \notin A$, $u(x) = 0$ para $x \in A$, solución única bajo condiciones de recurrencia positiva.

Ejercicio 5.8 (Función de Lyapunov)

Si $LV(x) \leq -cV(x) + b\mathbb{1}_C(x)$, entonces $M_t = V(X_t) - V(X_0) - \int_0^t LV(X_s)ds$ es martingala. Tomando esperanzas, se obtienen cotas para los tiempos de retorno a C .

Ejercicio 5.9

Para $\tau_a = \inf\{t : M_t \geq a\}$, con $M_t = N_t - \lambda t$. Aplicando el teorema de paro opcional a $M_{t \wedge \tau_a}$, se tiene $\mathbb{E}[M_{t \wedge \tau_a}] = 0$. Haciendo $t \rightarrow \infty$, si τ_a es finito c.s., $M_{\tau_a} = a$ en el instante del salto, pero hay que tener cuidado con el overshoot. Se obtiene $\mathbb{E}[\tau_a] = \frac{\mathbb{E}[N_{\tau_a}]}{\lambda}$.

Ejercicio 5.10 (Riesgo y martingala exponencial)

La condición $c\theta - \lambda(\mathbb{E}[e^{\theta Y_1}] - 1) = 0$ implica que $Z_t = e^{-\theta R_t}$ es martingala. Esta martingala se usa para calcular probabilidades de ruina: $\mathbb{P}(\inf_t R_t < 0) \leq e^{-\theta u}$ (desigualdad de Lundberg).

Ejercicio 5.11 (Simulación martingala compensada)

```
lam = 2.0
T = 5.0
dt = 0.01
t = np.arange(0, T, dt)
N = np.random.poisson(lam*dt, size=len(t)).cumsum()
M = N - lam*t
```

Ejercicio 5.12 (Simulación cambio de medida)

Se simulan trayectorias de N_t bajo $\mathbb{P}$, se calculan los pesos $Z_T^{(\theta)}$, y se estima la distribución bajo $Q^{(\theta)}$ mediante remuestreo ponderado, verificando que coincide con Poisson de media $\lambda e^{\theta T}$.